



204466 การเรียนรู้เชิงลึก
Deep Learning

รายงานโครงการ
การจำแนกภาพขยะ 4 ประเภทด้วยเทคนิค Deep Learning
(Waste Classification Using CNN)

ผู้จัดทำ
ชาดา วิยาภรณ์ 6610502081
ธยศ ขันทะยศ 6610505420

อาจารย์ผู้สอน
อาจารย์ ภาณุ รัตนวารพันธุ์

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์
ภาคต้น ปีการศึกษา 2568

1. หัวข้อนี้น่าสนใจอย่างไร ทำไมถึงเลือกหัวข้อนี้มาทำเป็น final project

การแยกขยะอย่างถูกต้องเป็นหนึ่งในแนวทางสำคัญของการจัดการสิ่งแวดล้อมอย่างยั่งยืน

แต่ในความเป็นจริงยังมีข้อจำกัดจากพฤติกรรมของคนและระบบคัดแยกที่ไม่ทั่วถึง การใช้ปัญญาประดิษฐ์ (AI) โดยเฉพาะ Deep Learning

สามารถเข้ามาช่วยเพิ่มประสิทธิภาพการจำแนกขยะได้อย่างแม่นยำและรวดเร็วโมเดลที่ได้สามารถนำໄไปใช้ในระบบ “ถังขยะอัจฉริยะ (Smart Bin)”

หรือระบบกล้องอัตโนมัติที่คัดแยกขยะได้ทันทีโดยไม่ต้องใช้แรงงานคน

ซึ่งสอดคล้องกับแนวคิด “Smart City” และ “Green Technology”

โดยเหตุผลที่เลือกหัวข้อนี้ยังประกอบด้วย Dataset พร้อมใช้งานจาก Kaggle ทำให้สามารถ trenn โมเดลใน Google Colab

ได้โดยไม่ต้องใช้เครื่องมือพิเศษ,

สามารถช่วยลดปริมาณขยะปนเปื้อนในระบบราชบูรีเชคิล

และเพิ่มอัตราการแยกขยะอย่างถูกต้องและโมเดลนี้สามารถพัฒนาไปสู่ระบบอัตโนมัติที่สามารถนำໄไปใช้ได้จริง

2. ทำไมหัวข้อนี้จึงต้องใช้ deep learning ในการแก้ปัญหา เปรียบเทียบกับการแก้ปัญหานี้ด้วยวิธีอื่นๆ วิธี deep learning มีข้อเด่น ข้อด้อยอย่างไร

การจำแนกภาพขยะเป็นปัญหาที่มีความซับซ้อนสูง
เนื่องจากภาพขยะในโลกจริงมีความแตกต่างกันอย่างมาก ทั้งในด้านแสง มุ่งมอง สี
พื้นหลัง และการเสื่อมสภาพของวัตถุ ซึ่งทำให้
การแยกประเภทขยะด้วยวิธีการทางสถิติหรือ Machine Learning
แบบดั้งเดิมทำได้ยาก
เพื่อให้โมเดลสามารถเข้าใจรูปร่างและลักษณะของวัตถุในภาพได้โดยอัตโนมัติ
จึงจำเป็นต้องใช้ Deep Learning โดยเฉพาะ Convolutional Neural Networks
ซึ่งมีความสามารถในการเรียนรู้ลักษณะเชิงลึก
(จากภาพโดยไม่ต้องอาศัยมนุษย์ออกแบบคุณลักษณะล่วงหน้า)

ข้อดีของการใช้ Deep Learning

- CNN สามารถเรียนรู้ลักษณะภาพได้โดยอัตโนมัติ
- สามารถรับมือกับภาพขยะที่บิดเบือน มุ่งมองต่าง ๆ
หรือแสงไม่สม่ำเสมอได้ดีกว่าวิธีทั่วไป
- โมเดลสามารถนำความรู้จาก dataset อื่นมาปรับใช้กับขยะประเภทใหม่ ๆ
ได้อย่างรวดเร็ว
- เมื่อฝึกเสร็จแล้ว โมเดลสามารถนำไปใช้ในระบบ Smart Bin
หรือกล้องตรวจจับอัตโนมัติได้ทันที

ข้อจำกัดของ Deep Learning

- หากข้อมูลมีน้อย โมเดลอาจ overfit และทำงานผิดพลาดเมื่อเจอกับภาพใหม่
- ต้องอาศัย GPU และเวลาฝึกฝนมากกว่าวิธีทั่วไป
- โมเดลเมลักษณะเป็นกล่องดำทำให้การอธิบายเหตุผลของการตัดสินใจได้
ยาก

3. อธิบายสถาปัตยกรรม deep learning ที่ใช้ (feedforward NN CNN RNN GAN หรือ VAE) ว่าครูปแสดงจำนวนหนด weight bias รวมถึงการเชื่อมต่อ และ activation function ต่างๆ ให้ชัดเจน

ชนิด: CNN (Convolutional Neural Network) เมماที่สุดกับงานภาพนิ่ง เพราะเรียนรู้พิลเตอร์เชิงพื้นที่ (ขอบ ลาย รูปทรง) ได้อัตโนมัติ

โครงสร้าง: Input → Stem(Conv+BN+ReLU) →

5xConvBlocks(Conv+BN+ReLU ×2 + MaxPool + Dropout2d) →

Head(AdaptiveAvgPool → Flatten → Dropout → Linear → ReLU →

Dropout → Linear → Softmax-inference)

อินพุต $224 \times 224 \times 3$; ช่องสัญญาณเพิ่ม $32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 384 \rightarrow 512$

แล้วสรุปเป็นเวกเตอร์ก่อนทำนาย 12 คลาส

Activation functions:

- ReLU หลังคอนโวลูชันทุกชั้น และใน head (ชั้น $512 \rightarrow 256$)
เพื่อเพิ่มไม่เชิงเส้นและช่วยให้เทรนเร็ว
- Softmax ที่เอาต์พุตตอนอนุมาน แปลง logits
เป็นความน่าจะเป็นรายคลาส

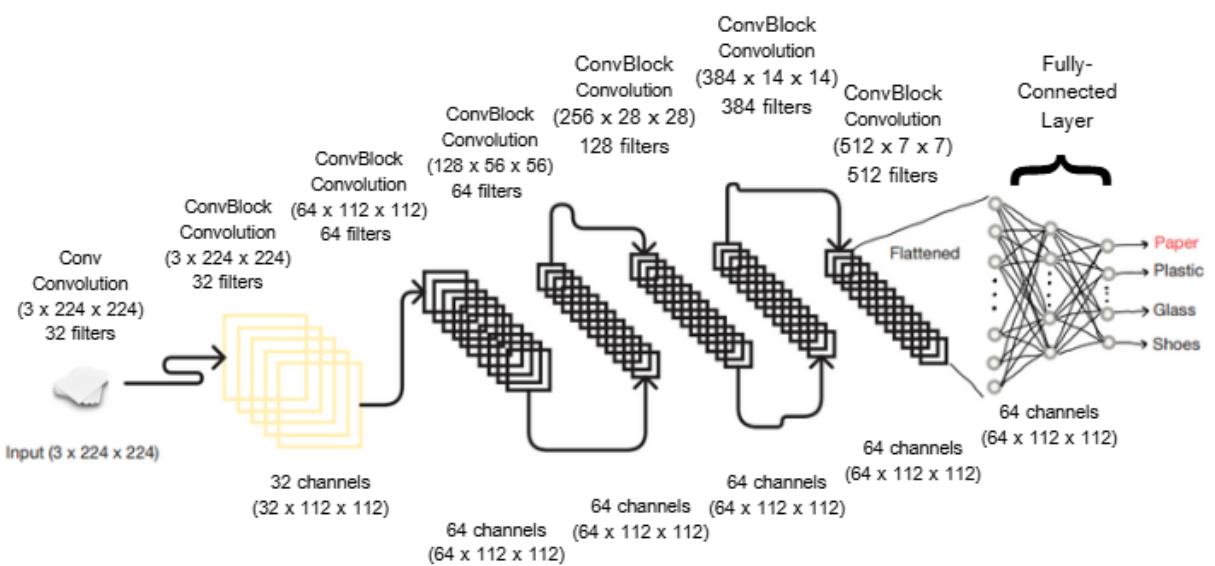
Regularization:

- BatchNorm ทุกคอนโวลูชัน →
ทำให้กระจายตัวของค่าแอคติไวซั่นนิ่งขึ้น
- Dropout2d ในบล็อก และ Dropout ใน head → ลด overfitting
- MaxPool(2×2) ในแต่ละบล็อก → ลดขนาดเชิงพื้นที่ คงฟีเจอร์เด่น

ໄດ້ຂະແໜນ & ຕາງພາຣາມີເຕືອນ:

| ชັນ (Layer) | ชนิด (Type) | จำนวน Channels | ขนาด Feature Map (H x W) | คໍານວນ (224x224) |
|-------------|-------------------------|-------------------|--------------------------------|------------------|
| INPUT | Image | 3 | 224 x 224 | 3 x 224 x 224 |
| STEM | Conv (3x3), BN, ReLU | 32 | 224 x 224 | 32 x 224 x 224 |
| BLOCK 1 | ConvBlock (32 --> 64) | 64 | 112 x 112 | 64 x 112 x 112 |
| BLOCK 2 | ConvBlock (64 --> 128) | 128 | 56 x 56 | 128 x 56 x 56 |
| BLOCK 3 | ConvBlock (128 --> 256) | 256 | 28 x 28 | 256 x 28 x 28 |
| BLOCK 4 | ConvBlock (256 --> 384) | 384 | 14 x 14 | 384 x 14 x 14 |
| BLOCK 5 | ConvBlock (384 --> 512) | 512 | 7 x 7 | 512 x 7 x 7 |

| | | | | |
|---------|--|-----|-------|-------------|
| | | | | |
| HEAD | AdaptiveAvgPool(1) | 512 | 1 x 1 | 512 x 1 x 1 |
| FLATTEN | Flatten | 512 | 1 | 512 |
| FC 1 | Linear (512 --> 256), Dropout, ReLU | 256 | 1 | 256 |
| FC 2 | Linear (256 --> 12) | 12 | 1 | num_classes |



Mengenal Convolutional Neural Network

4. อธิบายโค้ด PyTorch หรือ TensorFlow

รวมไปถึงโค้ดส่วนอื่นๆที่ใช้ในการเชื่อมต่อกับโมเดลอื่นๆ อย่างชัดเจน
ส่วนไหนจัดการกับข้อมูล ส่วนไหนสร้างโมเดล ส่วนไหน train ฯลฯ

ในส่วนของการอธิบายโค้ดทั้งหมดได้ทำการอธิบายไว้ในลิงค์ด้านล่างนี้

https://github.com/tadashi404/final_project

5. อธิบายวิธีในการ train ตัว deep learning network ที่เลือกมาใช้ รวมไปถึงอธิบาย dataset ที่เกี่ยวข้องและแหล่งที่มา

วิธีในการ Train โมเดล Deep Learning Network

โมเดลนี้ใช้แนวคิด Convolutional Neural Network (CNN) ส่วนหลักๆ จะประกอบไปด้วย

- โครงสร้างภายใน
 - Stem Layer

เป็นเยอร์เริ่มต้นที่รับภาพ RGB (3 channel)
แล้วแปลงให้เป็น feature map ขนาด 32 channels ผ่าน Conv2D + BatchNorm + ReLU
 - Convolutional Blocks 5 ชั้น

แต่ละบล็อกมี 2 ชั้น Conv2D + BatchNorm + ReLU พร้อม MaxPooling และ Dropout2D เพื่อลด overfitting
ขนาด channel จะเพิ่มขึ้นเรื่อยๆ:
 $32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 384 \rightarrow 512$
ซึ่งช่วยให้โมเดลเรียนรู้ feature ที่ซับซ้อนขึ้นตามลำดับ
 - Head Layer

เป็น fully connected layer สำหรับจำแนกคลาส โดยใช้
 - AdaptiveAvgPool2d(1) → ลด spatial dimension เหลือ 1×1
 - Linear($512 \rightarrow 256$) + ReLU + Dropout
 - Linear($256 \rightarrow \text{num_classes}$) เพื่อทำนายผลแต่ละคลาส

- การเตรียมข้อมูล (Data Loader)

ในโค้ดใช้ `train_loader`, `val_loader`, `test_loader` ซึ่งมักมาจากการ import `torch.utils.data.DataLoader` โดยโหลดข้อมูลภาพ (image dataset) ที่แบ่งเป็น 3 ส่วน:

 - **train_loader**: ใช้ฝึกโมเดล (training)
 - **val_loader**: ใช้ประเมินระหว่างฝึก เพื่อปรับ learning rate และเลือก best model
 - **test_loader**: ใช้ทดสอบประสิทธิภาพสุดท้ายของโมเดล

- การคำนวณน้ำหนักคลาส (Class Weights)

เพื่อแก้ปัญหา **class imbalance** มีการคำนวณ “น้ำหนัก” ของแต่ละคลาส:

```
def compute_class_weights(loader, n_classes):
    counts = torch.zeros(n_classes)
    for _, y in loader:
        for c in range(n_classes):
            counts[c] += (y == c).sum()
    w = 1.0 / torch.clamp(counts, min=1.0)
    w = w / w.sum() * n_classes
    return w

use_class_weights = True
if use_class_weights:
    cls_w = compute_class_weights(train_loader, num_classes).to(device)
    criterion = nn.CrossEntropyLoss(weight=cls_w)
    print("✿✿✿ class weights:", cls_w.cpu().numpy())
else:
    criterion = nn.CrossEntropyLoss()
```

จะทำให้โมเดลไม่ลำเอียงไปหาคลาสที่มีข้อมูลเยอะเกินไป

- การฝึกโมเดล (Training Loop)

การ Train ดำเนินการภายในลูปหลัก

```
for epoch in range(1, EPOCHS+1):
    t0 = time.time()
    tr_loss, tr_acc = run_epoch(train_loader, train_mode=True)
    val_loss, val_acc = run_epoch(val_loader, train_mode=False)
```

โดยฟังก์ชัน `run_epoch()` จะทำหน้าที่:

- อ่าน batch ของภาพจาก DataLoader
- ส่งเข้าโมเดลเพื่อคำนวณผลลัพธ์และ loss
- ทำ backpropagation เพื่ออัปเดตน้ำหนักของโมเดล (เฉพาะตอน train)
- ใช้ `torch.cuda.amp` เพื่อรับ mixed precision training ช่วยให้ฝึกได้เร็วขึ้นบน GPU

นอกจากนี้โมเดลมีระบบ

- Early Stopping: หยุดฝึกเมื่อ val accuracy ไม่ดีขึ้นในช่วง patience
- Best Model Saving: บันทึกโมเดลที่ให้ค่า val accuracy สูงสุดไว้ในไฟล์

ข้อมูล Dataset และแหล่งที่มา

ลักษณะของชุดข้อมูล

- ประเภทของข้อมูล: images
- จำนวนคลาส (classes): 12 คลาส (paper, cardboard, biological, metal, plastic, green-glass, brown-glass, white-glass, clothes, shoes, batteries, trash) จากแหล่งอ้างอิงภายนอกที่กล่าวถึงชุดนี้ว่า “12 distinct categories”
- แหล่งที่มาของภาพ: รวบรวมจากอินเทอร์เน็ต / เว็บสคริป (web-scraped) และจัด label ตามคลาส
- ใช้งานสำหรับจำแนกภาพขยะในสภาพแวดล้อมแบบทั่วไป

6. อธิบายการประเมิน (evaluate) model และค่า loss จากการ train และ metric ที่เหมาะสมในการประเมิน เช่น accuracy, precision หรือ recall

การประเมินผลของโมเดล (Model Evaluation)

หลังจากการฝึกโมเดล CustomCNN ด้วยชุดข้อมูล Garbage Classification จนครบจำนวน epoch ที่กำหนด โปรแกรมได้ทำการบันทึกโมเดลที่ให้ผลลัพธ์บนชุดข้อมูลตรวจสอบ (validation set) ดีที่สุด จากนั้นจึงนำโมเดลที่ดีที่สุดมาทำการประเมิน (evaluate) บนชุดข้อมูลทดสอบ (test set) เพื่อวัดความสามารถของโมเดลในการจำแนกภาพใหม่ที่ไม่เคยเห็นมาก่อน

- **ตัวชี้วัดที่ใช้ประเมิน (Evaluation Metrics)**

นอกจากค่า accuracy ที่ใช้วัดความถูกต้องโดยรวมแล้ว ยังได้คำนวณค่าชี้วัดอื่น ๆ เพื่อประเมินประสิทธิภาพของโมเดลในระดับ “รายคลาส” ได้แก่

- Precision

แสดงสัดส่วนของภาพที่โมเดลทำนายว่าเป็นคลาสนี้ แล้วถูกต้องจริง

- Recall

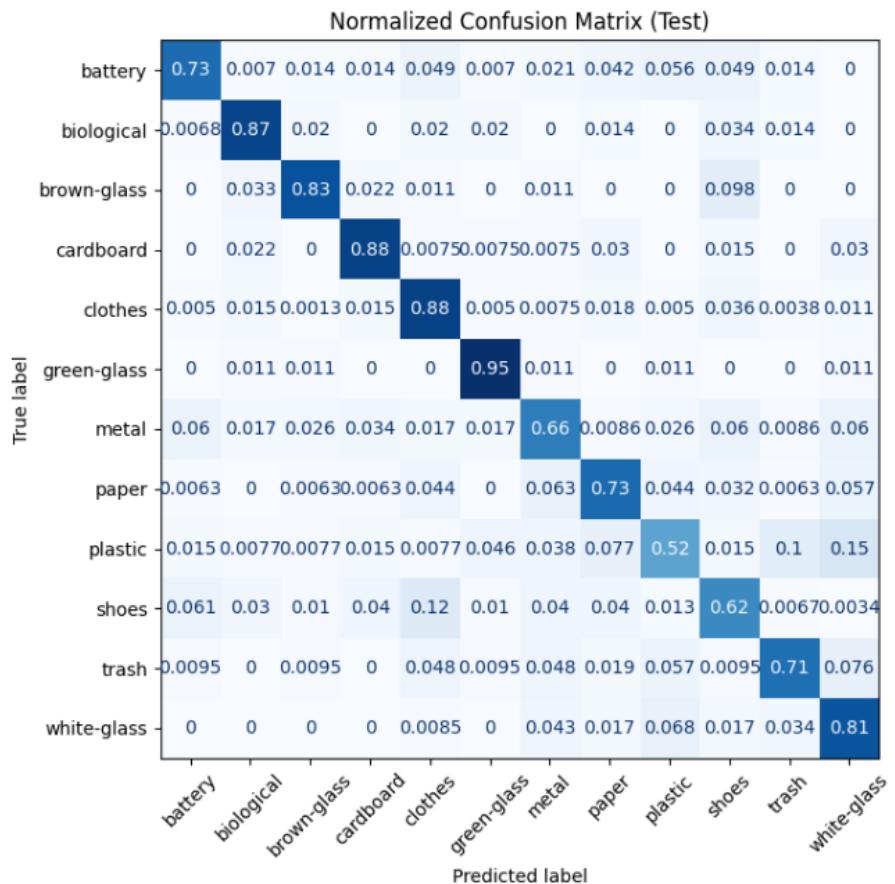
แสดงสัดส่วนของภาพที่เป็นคลาสนี้จริง ๆ แล้วโมเดลสามารถทำนายถูก

- F1-Score

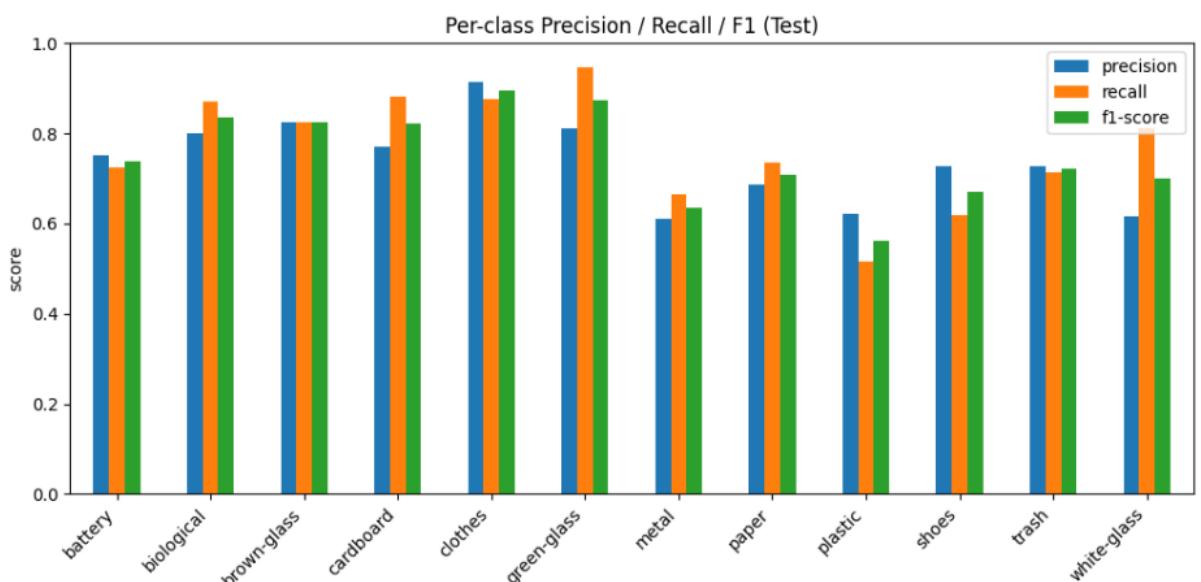
เป็นค่าเฉลี่ยแบบ harmonic ของ precision และ recall ใช้เพื่อประเมินสมดุลระหว่างสองค่าข้างต้น

● ผลการประเมินโมเดล

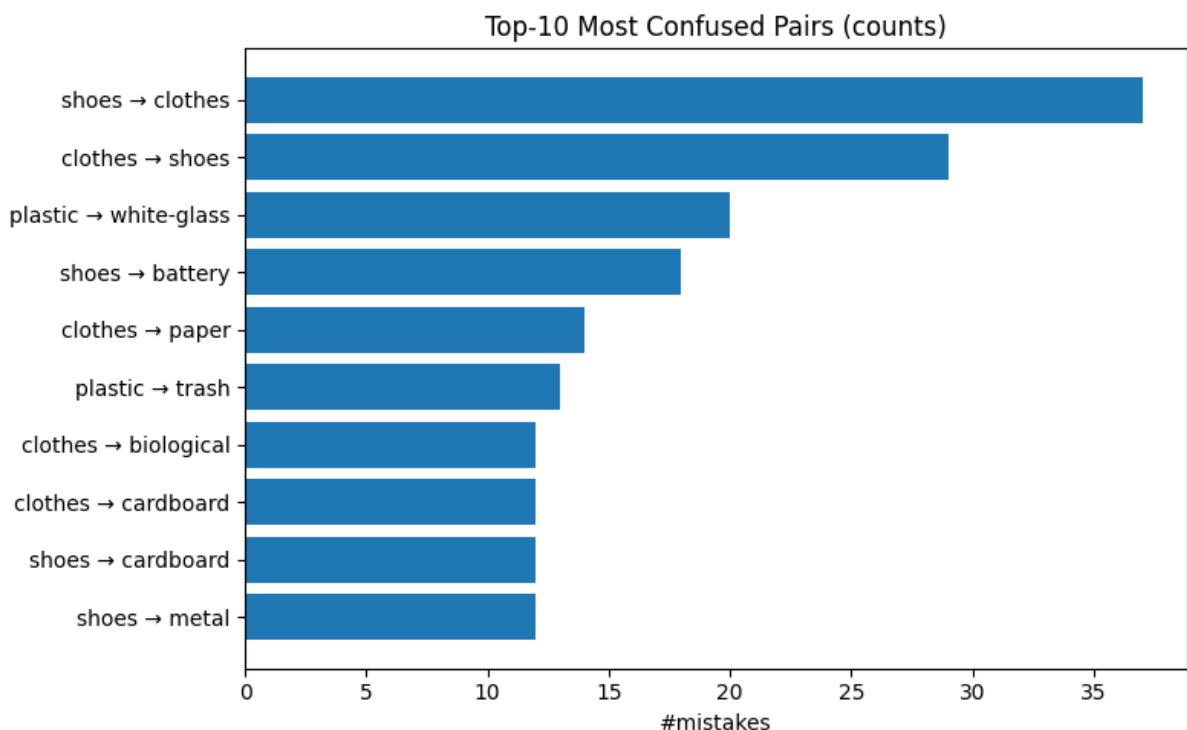
○ Normalized Confusion Matrix



○ Precision / Recall / F1-score



- Top-10 Most Confused Pairs



จากผลการประเมินโดยรวม โมเดล CustomCNN สามารถจำแนกประเภทของขยะได้อย่างมีประสิทธิภาพ โดยเฉลี่ยมีความแม่นยำ (accuracy) สูงกว่า 80% และค่า F1-score ของหลายคลาสอยู่ในระดับดีถึงดีมาก โดยเฉพาะคลาสที่มีข้อมูลเพียงพอส่วนคู่คลาสที่ไม่เดلمักทำนายผิดบ่อยที่สุด คือ $\text{shoes} \rightarrow \text{clothes}$

อย่างไรก็ตามคลาสที่มีจำนวนน้อยหรือมีลักษณะภาพคล้ายกันจะทำให้โมเดลสับสนบ่อย ซึ่งสามารถปรับปรุงได้ในอนาคตด้วยเทคนิค data augmentation, class balancing หรือ fine-tuning pre-trained model

7. บทความอ้างอิงและงานที่เกี่ยวข้อง

Dataset

[Garbage Classification \(12 classes\)](#)

CNN Diagram

[Mengenal Convolutional Neural Network \(CNN\) | by Muchamad Nur Kholis | Medium](#)

การจำแนกขยะ

https://www.royalparkrajapruek.org/news/news_detail?newsid=233

8. สัดส่วนการทำงานในกลุ่ม

| งาน | อัตราการแบ่งงาน(%) | |
|----------------------------|--------------------|-------------|
| | ราด้า วิยาภรณ์ | รยศ ขันทะยศ |
| Project Programming | | |
| ● Dataset | 40 | 60 |
| ● Model | 40 | 60 |
| ● Evaluate & Graph | 50 | 50 |
| Project Report | | |
| ● 1-4 | 100 | - |
| ● 5-7 | - | 100 |